

Facultad de Ciencias Básicas, Ingeniería y Arquitectura

Unidad I: Presentación y Descripción de la Información

Susan Santamaría Campo
Licenciada en Matemática
Magíster en Estadística Aplicada

Corporación Universitaria del Caribe – CECAR

20 de febrero de 2026

Contenido de la presentación

1. ¿Qué es estadística?

1.1 Estadística Descriptiva

1.2 Estadística Inferencial

1.3 Conceptos Básicos

1.4 Tipos de Variables

1.5 Distribuciones de frecuencias univariada

- Distribución de frecuencias para datos cualitativa
- Distribuciones de frecuencias para datos no agrupados
- Distribuciones de frecuencias para datos agrupados

1.6 Medidas de tendencias

- Medidas de posición
- Medidas de forma

1.7 Medidas de dispersión

- Varianza
- Desviación típica o desviación estándar
- Coeficiente de variación.

1.8 Bibliografía

¿Qué es estadística?

Es la ciencia que se ocupa de:

- Recolección, organización y análisis de datos
- Obtención de inferencias a partir de muestras

Objetivo: Interpretar y comunicar información contenida en datos.

- Organiza y resume datos
- Uso de tablas y gráficos
- Cálculo de parámetros
- No usa probabilidades
- Con este método, se obtienen conclusiones sobre el conjunto de datos sin que sobrepasen el conjunto de conocimientos que proporcionan.

- Generaliza resultados de una muestra a una población
- Usa modelos probabilísticos
- Permite realizar predicciones

Conceptos Básicos

Población: Conjunto total de elementos.

Muestra: Subconjunto representativo.

Variable: Característica que varía entre individuos.

Tipos de Variables

Cuantitativas

Es una variable estadística que representa cantidades numéricas medibles, permitiendo realizar operaciones matemáticas como sumar, restar, promediar o calcular porcentajes. Ejemplos: edad, peso, estatura, ingreso, número de hijos.

- Discreta: toma valores enteros (número de estudiantes).
- Continua: toma cualquier valor dentro de un intervalo (altura, temperatura).

Cualitativas

Es una variable estadística que describe características o categorías, cuyos valores no son numéricos ni permiten operaciones matemáticas.

- Nominal: categorías sin orden (género, nacionalidad).
- Ordinal: categorías con orden o jerarquía (nivel educativo, satisfacción: bajo-medio-alto).

Distribuciones de frecuencias para datos cualitativa

Una tabla de frecuencias cualitativas organiza datos categóricos mostrando cuántas veces aparece cada categoría.

Frecuencia absoluta (f_a): Número de veces que se repite un dato.

Frecuencia relativa (f_r): Cociente entre cada f_a sobre n número de total de datos

$$f_r = \frac{f_a}{n} \times 100$$

Ejemplo: Lenguaje de programación preferido por 20 estudiantes de Ingeniería de Sistemas.

Lenguaje	f_a	f_r	%
Python	7	0.35	35 %
Java	5	0.25	25 %
C++	3	0.15	15 %
JavaScript	4	0.20	20 %
Otros	1	0.05	5 %
Total	20	1.00	100 %

Distribución de frecuencias para no datos agrupados

- Marca de clase (X_i): Son las observaciones.
- Frecuencia absoluta (f_a): Es el número de veces que se repite cada observación.
- Frecuencia acumulada (FA): Es la suma sucesiva de la frecuencia absoluta.
- Frecuencia relativa (f_r): Es la relación entre la frecuencia absoluta y el total de observaciones multiplicado por cien. Esto es:
- Frecuencia relativa acumulada (FR): Es la suma sucesiva de la frecuencia relativa.

$$f_r = \frac{f_a}{n} \times 100$$

Ejemplo: Datos No Agrupados

Situación: Número de horas dedicadas a programar en una semana por 15 estudiantes de Ingeniería de Sistemas.

Datos ordenados:

5, 5, 5, 6, 6, 6, 7, 7, 7, 8, 8, 8, 9, 9, 10

Ejemplo: Datos No Agrupados

Situación: Número de horas dedicadas a programar en una semana por 15 estudiantes de Ingeniería de Sistemas.

Datos ordenados:

5, 5, 5, 6, 6, 6, 7, 7, 7, 8, 8, 8, 9, 9, 10

Tabla de Frecuencias

Horas	f_a	FA	f_r	FR
5	3	3	0.20	0.20
6	3	6	0.20	0.40
7	3	9	0.20	0.60
8	3	12	0.20	0.80
9	2	14	0.13	0.93
10	1	15	0.07	1.00
Total	15		1.00	

Distribuciones de frecuencias para datos agrupados

Cuando los datos son numerosos o corresponden a la variable cuantitativa continua, la ordenación en forma creciente ya no es funcional y, por lo tanto, se deben agrupar los datos en intervalos, mediante el siguiente procedimiento: calcular rango o recorrido, número de intervalos o clases, amplitud del intervalo de clase, límites de los intervalos y tabulación.

Distribuciones de frecuencias para datos agrupados

- Rango o recorrido: El rango o recorrido (R) se define como la variación numérica de la variable, es el recorrido que toma la variable desde el valor más pequeño hasta el valor más alto. Se calcula mediante la siguiente ecuación:

$$R = X_{\text{máx}} - X_{\text{mín}}$$

- R : Rango
- $X_{\text{máx}}$: Valor máximo del conjunto de datos
- $X_{\text{mín}}$: Valor mínimo del conjunto de datos

Distribuciones de frecuencias para datos agrupados

- Número de intervalos o clases: El número de intervalos (m) se define de forma convencional, procurando mantenerse entre 5 y 20 intervalos o clases. Sin embargo, para evitar caer en los extremos, es posible obtener una aproximación usando la fórmula propuesta por Sturges (Martínez, 2007), la cual es:

$$k = 1 + 3.322 \log_{10}(n)$$

Donde:

- k : número de clases o intervalos
- n : tamaño de la muestra.

Distribuciones de frecuencias para datos agrupados

- Amplitud del intervalo de clase: La amplitud de los intervalos (A) no es necesaria que sea igual para todos; sin embargo, con el objeto de simplificar y volverlo más funcional, es conveniente que todos los intervalos tengan igual amplitud. Para el cálculo de la amplitud del intervalo se toma el cociente entre el rango (R) y el número de intervalos (K) que se considere más adecuado, teniendo en cuenta que este resultado (A) debe ser una cantidad exacta.

$$A = R/k$$

Distribuciones de frecuencias para datos agrupados

- Límites de los intervalos y tabulación: construir los intervalos, cada uno de ellos está determinado por dos extremos: límite inferior (L_i) y límite superior (L_s). Para el primer intervalo, el límite inferior es igual al límite inferior del rango L_i y el límite superior de este intervalo se conforma sumando la amplitud (A) al límite inferior. El segundo intervalo parte del límite superior del primer intervalo y se le suma la amplitud para obtener el límite superior. Este proceso se repite para el total de intervalos en los cuales se agrupó el conjunto de datos.

Distribuciones de frecuencias para datos agrupados

- Marca de clase: La marca de clase, conocida también como punto medio, es el valor representativo para cada intervalo. Se representa por x_i y se calcula promediando el límite inferior L_i y superior L_s en cada intervalo. La fórmula para el cálculo es:

$$A = (L_s + L_i)/2$$

Ejercicio Aplicado – Ingeniería de Sistemas

En el programa de Ingeniería de Sistemas se realizó un seguimiento académico para analizar el número de proyectos de programación desarrollados por un grupo de 20 estudiantes durante dos semestres académicos, con el propósito de evaluar el nivel de práctica en desarrollo de software.

Datos observados

4 12 8 14 11 6 7 13 13 11

11 20 5 19 10 15 24 7 29 6

Actividades

- 1 Construir la tabla de distribución de frecuencias.
- 2 Interpretar los resultados obtenidos.
- 3 ¿Cuántos estudiantes desarrollaron mayor número de proyectos? ¿Porcentaje?

Ejercicio Contextualizado

Contexto Ingeniería de Sistemas

Un grupo de estudiantes de Ingeniería de Sistemas realiza pruebas de rendimiento en servidores virtuales. Los siguientes datos corresponden al tiempo de respuesta (en milisegundos) registrado en 50 ejecuciones de un algoritmo.

163 144 190 158 138 180 164 193 195 159
178 196 189 152 174 168 170 167 146 198
147 174 190 165 134 175 168 172 165 180
194 199 136 169 169 151 198 184 202 176
196 178 154 180 153 174 170 166 183 152

Se pide:

- 1 Construir la tabla de frecuencias agrupadas.
- 2 Interpretar los resultados obtenidos.
- 3 Si un dato tiene exactamente el valor 164 ms y el intervalo es $[154, 164)$, ¿pertenece a este intervalo?
- 4 ¿Cuál es el porcentaje de estudiantes que obtiene tiempos de respuesta menor a 174ms?

Medidas de Tendencia Central

Las **medidas de tendencia central** permiten determinar la posición de un valor representativo dentro de un conjunto de datos, el cual resume el comportamiento general de todas las observaciones.

Dentro de las medidas de tendencia central se encuentran:

- Media aritmética - Mediana- Moda

Media Aritmética (Promedio) $\bar{x}$

Es la medida más conocida y sencilla de calcular. Presenta gran estabilidad en el muestreo y sus fórmulas permiten tratamientos algebraicos. Su principal desventaja es que es sensible a valores extremos o atípicos.

La media se define como:

$$\bar{x} = \frac{\sum x_i}{n}$$

Para datos agrupados en tablas de frecuencia:

$$\bar{x} = \frac{\sum (x_i \cdot f_a)}{n}$$

Mediana (Me)

Mediana (Me): Valor central de un conjunto de datos ordenados. Es única, simple y poco sensible a valores extremos.

a. Número impar de observaciones: Ordenar los datos de menor a mayor (o viceversa) y seleccionar el valor central.

b. Número par de observaciones: La mediana corresponde al promedio de los dos valores centrales.

Para datos agrupados:

$$M_e = L_I + \left(\frac{\frac{n}{2} - F_{(A-1)}}{f_a} \right) A$$

Donde:

- L_I : Límite inferior de la clase mediana
- $F_{(A-1)}$: Frecuencia acumulada anterior
- f_a : Frecuencia absoluta de la clase mediana
- A : Amplitud del intervalo

Moda (Mo)

Moda (Mo): Valor de la variable que presenta la mayor frecuencia. Puede calcularse en variables cuantitativas y cualitativas.

- Si existen dos o más valores con frecuencia máxima, la distribución es **bimodal** o **multimodal**.
- Si todas las observaciones tienen igual frecuencia, la distribución **no presenta moda**.

Para datos agrupados:

$$M_o = L_I + \left(\frac{f_a - f_{(a-1)}}{(f_a - f_{(a-1)}) + (f_a - f_{(a+1)})} \right) A$$

Donde:

- L_I : Límite inferior de la clase modal
- f_a : Frecuencia absoluta de la clase modal
- $f_{(a-1)}$: Frecuencia anterior a la clase modal
- $f_{(a+1)}$: Frecuencia posterior a la clase modal
- A : Amplitud del intervalo

Actividad

- 1 Calcular las medidas de tendencia central para los ejemplos anteriores.
- 2 Interpretar los resultados obtenidos.

Medidas de posición

Cuando la distribución contiene un número alto de intervalos o de marca de clases y se requiere obtener un promedio de una parte de ella, se puede dividir la distribución en cuatro, diez o cien partes. En el primer caso se habla de cuartiles, en el segundo se denomina deciles y en el último centiles o percentiles.

Son los tres valores que dividen al conjunto de datos ordenados en cuatro partes iguales.

- El primer cuartil Q_1 : Lo que significa que el 25 % de los datos cae por debajo del primer cuartil.
- El segundo cuartil Q_2 (la mediana): Lo que significa que el 50 % de los datos cae por debajo del segundo cuartil.
- El tercer cuartil Q_3 : Lo que significa que el 75 % de los datos cae por debajo del tercer cuartil. Los cuartiles son:

Cuartiles

Si los datos no están agrupados:

$$Q_i = \begin{cases} \frac{i(n+1)}{4} & \text{si } n \text{ es impar} \\ \frac{in}{4} & \text{si } n \text{ es par} \end{cases}$$

Con $i = 1, 2, 3$

Para una tabla de frecuencias de datos agrupados los cuartiles se hallan de la siguiente manera:

$$Q_i = L_i + \left(\frac{\frac{in}{4} - F_{(A-1)}}{fa} \right) \times A$$

Con $i = 1, 2, 3$

Donde:

- L_i : Es el límite inferior de la clase que contiene al cuartil.
- $F_{(A-1)}$: Frecuencia absoluta acumulada anterior a la clase que contiene al cuartil.
- f_a : Frecuencia absoluta de la clase que contiene al cuartil.
- A : Amplitud.

Ejemplo: Cuartiles no agrupados

Un ingeniero de sistemas mide el tiempo de respuesta (ms) de un servidor en 7 solicitudes consecutivas.

Datos registrados:

7, 8, 5, 10, 4, 12, 2

Datos ordenados:

2, 4, 5, 7, 8, 10, 12

Número de datos:

$n = 7$ (impar)

Fórmula:

$$Q_i = \frac{i(n+1)}{4}$$

Cálculo

$$Q_1 = \frac{1(7+1)}{4} = 2 \Rightarrow Q_1 = 4$$

Ejemplo: Cuartiles agrupados

En un laboratorio de Ingeniería de Sistemas, se analizó el tiempo de respuesta (en milisegundos) de un servidor cuando los estudiantes ejecutan consultas a una base de datos durante una práctica de programación.

Para estudiar el rendimiento del sistema, se registraron 30 mediciones del tiempo de respuesta y luego se organizaron en intervalos de clase para construir una tabla de frecuencias siguiente;

Intervalo	fa	FA
0-10	5	5
10-20	9	14
20-30	12	26
30-40	4	30

Total de datos:

$$n = 30$$

Ejemplo: Cuartiles agrupados

Cálculo de Q_1

$$\frac{n}{4} = \frac{30}{4} = 7.5$$

La clase que contiene el cuartil es $10 - 20$.

$$L_i = 10, \quad F_{(A-1)} = 5, \quad fa = 9, \quad A = 10$$

$$Q_1 = 10 + \left(\frac{7.5 - 5}{9} \right) 10$$

$$Q_1 = 10 + 2.78 = 12.78$$

Deciles

son los nueve valores que dividen al conjunto de datos ordenados en diez partes iguales. Los deciles son: **Para datos no agrupados**

$$D_i = \begin{cases} \frac{i(n+1)}{10} & \text{si } n \text{ es impar} \\ \frac{in}{10} & \text{si } n \text{ es par} \end{cases}$$

Con $i = 1, 2, 3, \dots, 9$

Para datos agrupados

$$D_i = L_i + \left(\frac{\frac{in}{10} - F_{(A-1)}}{f_a} \right) A$$

Donde

- L_i : Límite inferior de la clase que contiene el decil
- $F_{(A-1)}$: Frecuencia acumulada anterior a la clase del decil
- f_a : Frecuencia de la clase que contiene el decil
- A : Amplitud

Ejemplo: Deciles no agrupados

En una empresa de desarrollo de software, el equipo de ingeniería de sistemas está evaluando el tiempo (en minutos) que tarda un sistema en procesar ciertas tareas automatizadas del servidor durante distintas pruebas. Para el análisis se registraron los siguientes tiempos de procesamiento (en el orden en que ocurrieron las pruebas): 11, 3, 18, 7, 5, 20, 9, 15, 8, 13. Estos datos se utilizarán para realizar un análisis estadístico del rendimiento del sistema. **Datos ordenados**

3, 5, 7, 8, 9, 11, 13, 15, 18, 20

$$n = 10$$

Cálculo de D_3

$$D_3 = \frac{3n}{10}$$

$$D_3 = \frac{3(10)}{10} = 3$$

El tercer valor es: $D_3 = 7$

Ejemplo: Deciles agrupados

Tabla de frecuencias

Intervalo	Frecuencia
0-10	4
10-20	6
20-30	10
30-40	5

$$n = 25$$

Cálculo de D_4

$$\frac{4n}{10} = \frac{4(25)}{10} = 10$$

Clase del decil: 20 – 30

$$L_i = 20, \quad F_{(A-1)} = 10, \quad fa = 10, \quad A = 10$$

$$D_4 = 20 + \left(\frac{10 - 10}{10} \right) 10 = 20$$

Percentiles

Son 99 valores que dividen el conjunto de datos ordenados en cien partes iguales. Los percentiles son:

Datos no agrupados

$$P_i = \begin{cases} \frac{i(n+1)}{100} & \text{si } n \text{ es impar} \\ \frac{in}{100} & \text{si } n \text{ es par} \end{cases}$$

Con $i = 1, 2, 3, \dots, 99$

Datos agrupados

$$P_i = L_i + \left(\frac{\frac{in}{100} - F_{(A-1)}}{f_a} \right) A$$

Donde

L_i : límite inferior de la clase del percentil

$F_{(A-1)}$: frecuencia acumulada anterior

No agrupados

Datos: 5, 7, 9, 10, 12, 15, 18, 20, 22, 25

$n = 10$

$$P_{30} = \frac{30n}{100} = \frac{30(10)}{100} = 3$$

$$P_{30} = 9$$

Ejemplos

Agrupados

Intervalo	f
0-10	3
10-20	7
20-30	8
30-40	2

$$n = 20$$

$$\frac{40n}{100} = 8$$

Clase: 10 – 20

$$P_{40} = 10 + \left(\frac{8-3}{7} \right) 10$$

$$P_{40} = 17.14$$

Medidas de forma


Las medidas de forma describen la forma de la distribución de los datos.

1. Asimetría

Indica si la distribución es simétrica o está inclinada hacia un lado.

Coeficiente de Pearson:

$$As = \frac{\bar{x} - Mo}{s}$$



- $As = 0$ distribución simétrica
- $As > 0$ asimetría positiva (cola a la derecha)
- $As < 0$ asimetría negativa (cola a la izquierda)


Curtosis

Mide el grado de concentración de los datos alrededor de la media.

$$K = \frac{\sum (x_i - \bar{x})^4}{ns^4}$$

Interpretación:

- $K = 3$ distribución normal (mesocúrtica)
- $K > 3$ distribución más concentrada (leptocúrtica)
- $K < 3$ distribución más plana (platicúrtica)



Ejemplo Asimetría

Datos:

4, 5, 6, 6, 7, 8, 9

Media:

$$\bar{x} = 6.43$$

Moda:

$$Mo = 6$$

Desviación estándar:

$$s = 1.72$$

Coeficiente de asimetría:

$$As = \frac{6.43 - 6}{1.72} = 0.25$$

Interpretación: ligera asimetría positiva.

Ejemplo Curtosis

Datos:

2, 4, 5, 6, 7, 8, 9

Número de datos:

$$n = 7$$

Media:

$$\bar{x} = 5.86$$

Desviación estándar:

$$s = 2.41$$

$$K = \frac{\sum (x_i - \bar{x})^4}{ns^4}$$

$$K = \frac{196.49}{7(2.41)^4}$$

$$K = 0.83$$

Interpretación:

$$K < 3$$

La distribución es **platicúrtica**.

Medidas de dispersión

Son aquellas que nos determinan como se agrupan o se dispersan los datos alrededor de un promedio (o media). Entre las más importantes tenemos: Varianza, desviación típica o desviación estándar y coeficiente de variación. Están dadas por:

Varianza poblacional

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$$

Varianza muestral

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

Desviación típica o desviación estándar

$$s = \sqrt{s^2}$$

Coeficiente de variación

$$CV = \frac{s}{\bar{x}} \times 100$$

Varianza Poblacional (Datos no agrupados)

Datos:

2, 4, 6, 8

Media poblacional:

$$\mu = \frac{2 + 4 + 6 + 8}{4} = 5$$

Fórmula:

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{N}$$

Cálculo:

$$\sigma^2 = \frac{(2 - 5)^2 + (4 - 5)^2 + (6 - 5)^2 + (8 - 5)^2}{4}$$

$$\sigma^2 = \frac{9 + 1 + 1 + 9}{4}$$

$$\sigma^2 = 5$$

Varianza Muestral (Datos agrupados)

Clase	f
0-10	2
10-20	4
20-30	2

Marcas de clase:

$$x_i = 5, 15, 25$$

Media muestral:

$$\bar{x} = \frac{\sum f_i x_i}{n}$$

$$\bar{x} = \frac{(2)(5) + (4)(15) + (2)(25)}{8} = 15$$

Cálculo Varianza Muestral Agrupada

$$s^2 = \frac{\sum f_i(x_i - \bar{x})^2}{n - 1}$$

$$s^2 = \frac{2(5 - 15)^2 + 4(15 - 15)^2 + 2(25 - 15)^2}{7}$$

$$s^2 = \frac{200 + 0 + 200}{7}$$

$$s^2 = 57.14$$

Tablas de frecuencias bi-variadas

Definición

Una **tabla de frecuencia bivariada** es una tabla que organiza datos para estudiar la relación entre **dos variables** al mismo tiempo.

Características

- Presenta las categorías de una variable en las **filas**.
- Presenta las categorías de la otra variable en las **columnas**.
- Cada celda muestra la **frecuencia conjunta**, es decir, cuántas veces ocurren simultáneamente ambas categorías.

Utilidad

- Permite analizar la relación entre dos variables.
- Facilita identificar patrones o asociaciones en los datos.
- Es la base para análisis estadísticos como probabilidades conjuntas y estudios de dependencia entre variables.

Ejemplo: Tablas de frecuencias bi-variadas

En un curso de programación de Ingeniería de Sistemas, el docente analiza si el **tiempo de práctica en programación** influye en si los estudiantes **logran ejecutar correctamente un programa** durante una práctica de laboratorio.

Se registraron dos variables:

- X : Horas de práctica
- Y : Resultado del programa (Correcto o Incorrecto)

Datos observados

Estudiante	Horas de práctica (X)	Resultado (Y)
1	1	Incorrecto
2	2	Correcto
3	3	Correcto
4	2	Incorrecto
5	4	Correcto
6	3	Correcto

Resultado: Tabla de frecuencia bivariada

Tabla de doble entrada

Horas de práctica (X)	Correcto	Incorrecto	Total
1	0	1	1
2	1	1	2
3	2	0	2
4	1	0	1
Total	4	2	6

Interpretación La mayoría de los estudiantes que practican más horas logran ejecutar el programa correctamente.

Walpole, R. E., Myers, R. H., Myers, S. L. & Ye, K. (2012). *Probabilidad y Estadística para Ingeniería y Ciencias*. Pearson Educación.

Triola, M. F. (2018). *Estadística*. Pearson.

Montgomery, D. C. & Runger, G. C. (2014). *Probabilidad y Estadística Aplicadas a la Ingeniería*. Wiley.